

inspeccio_dades

December 1, 2025

1 Font de les dades

https://opendata-ajuntament.barcelona.cat/data/es/dataset/pad_mdb_niv-educa-esta_edat-q_sexe/resource/12aef64a-f2eb-4021-bb02-4114f2e9aa3d

2 Objectiu

Rang d'edat, barri i sexe de la població a partir de 16 anys que més estudia

```
[ ]: !wget -O 2025_pad_mdb_niv-educa-esta_edat-q_sexe.csv https://
      ↪opendata-ajuntament.barcelona.cat/data/dataset/
      ↪3dd366b7-a18f-42e1-ba7d-3ebb9f24e005/resource/
      ↪12aef64a-f2eb-4021-bb02-4114f2e9aa3d/download

--2025-11-30 16:13:08-- https://opendata-ajuntament.barcelona.cat/data/dataset/
3dd366b7-a18f-42e1-ba7d-3ebb9f24e005/resource/12aef64a-f2eb-4021-bb02-
4114f2e9aa3d/download
Resolving opendata-ajuntament.barcelona.cat (opendata-
ajuntament.barcelona.cat)... 52.138.192.38
Connecting to opendata-ajuntament.barcelona.cat (opendata-
ajuntament.barcelona.cat)|52.138.192.38|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://opendata-ajuntament.barcelona.cat/resources/bcn/EstadisticaPad
ro/pad/2025/2025_pad_mdb_niv-educa-esta_edat-q_sexe.csv [following]
--2025-11-30 16:13:09-- https://opendata-ajuntament.barcelona.cat/resources/bcn
/EstadisticaPadro/pad/2025/2025_pad_mdb_niv-educa-esta_edat-q_sexe.csv
Reusing existing connection to opendata-ajuntament.barcelona.cat:443.
HTTP request sent, awaiting response... 200 OK
Length: 634940 (620K) [text/csv]
Saving to: '2025_pad_mdb_niv-educa-esta_edat-q_sexe.csv'

2025_pad_mdb_niv-ed 100%[=====>] 620.06K  1.98MB/s    in 0.3s

2025-11-30 16:13:09 (1.98 MB/s) - '2025_pad_mdb_niv-educa-esta_edat-q_sexe.csv'
saved [634940/634940]
```

```
[ ]: # Importar la libreria de pandas
import pandas as pd

# Leer el archivo
df = pd.read_csv("2025_pad_mdb_niv-educa-esta_edat-q_sexe.csv")
```

2.1 Anàlisis de les dades

2.1.1 Dimensionalitat (files, columnes)

```
[ ]: files, columnes = df.shape

print(f"Files: {files}") # Registres
print(f"Columnes: {columnes}") # Atributs
```

Files: 11164

Columnes: 9

2.1.2 Descripció i tipus de variables

```
[ ]: df.describe()
```

```
[ ]:      Codi_Districte    Codi_Barri  NIV_EDUCA_esta    EDAT_Q \
count    11164.000000  11164.000000    11164.000000  11164.000000
mean         6.189627    36.606593         3.248298    11.265407
std         2.821158    21.269067         1.325192     5.095018
min          1.000000     1.000000         1.000000     3.000000
25%          3.000000    18.000000         2.000000     7.000000
50%          7.000000    36.000000         3.000000    11.000000
75%          8.000000    55.000000         4.000000    16.000000
max         10.000000    73.000000         6.000000    20.000000
```

```
      SEXE
count  11164.000000
mean      1.491670
std      0.499953
min       1.000000
25%       1.000000
50%       1.000000
75%       2.000000
max       2.000000
```

```
[ ]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 11164 entries, 0 to 11163
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
#   Column                Non-Null Count  Dtype
```

```

0   Data_Referencia  11164 non-null  object
1   Codi_Districte  11164 non-null  int64
2   Nom_Districte   11164 non-null  object
3   Codi_Barri      11164 non-null  int64
4   Nom_Barri       11164 non-null  object
5   Valor           11164 non-null  object
6   NIV_EDUCA_esta  11164 non-null  int64
7   EDAT_Q          11164 non-null  int64
8   SEXE            11164 non-null  int64

```

dtypes: int64(5), object(4)

memory usage: 785.1+ KB

2.1.3 Dades estadístiques (mitjana, máxim. mínim, desviació estàndard, distribucions)

Mitjana i mediana

```

[ ]: # Mitjana d'edat quincenal
mitjana_edat_quincenal = df['EDAT_Q'].mean()
print("Mitjana d'edat quincenal: ",mitjana_edat_quincenal)

```

Mitjana d'edat quincenal: 11.265406664278036

```

[ ]: import numpy as np
import matplotlib.pyplot as plt

edats = df["EDAT_Q"].values

mitjana_edat = np.mean(edats)
mediana_edat = np.median(edats)


plt.figure(figsize=(10,6))

# Histograma de edades
plt.hist(edats, bins=15, color='green', edgecolor='black', alpha=0.7,
        label='Edats')

plt.axvline(mitjana_edat, color='red', linestyle='dashed', linewidth=2,
        label=f'Mitjana: {mitjana_edat:.2f}')
plt.axvline(mediana_edat, color='blue', linestyle='dashed', linewidth=2,
        label=f'Mediana: {mediana_edat:.2f}')

plt.title('Distribució d\'edats amb mitjana i mediana')
plt.xlabel('Edat')
plt.ylabel('Nombre de persones')
plt.legend()
plt.show()

```



```
[ ]: # Mediana d'edat quincenal
mediana_edat_quincenal = df['EDAT_Q'].median()
print("Mediana d'edat quincenal: ",mediana_edat_quincenal)
```

Mediana d'edat quincenal: 11.0

Màxim i mínim

```
[ ]: # Màxim
maxim_valor = df['EDAT_Q'].max()
print("Màxim valor: ",maxim_valor)

# Mínim
minim_valor = df['EDAT_Q'].min()
print("Mínim valor: ",minim_valor)
```

Màxim valor: 20

Mínim valor: 3

Desviació estàndard

```
[ ]: # Desviació estàndard
desviacio_estandard_edat_q = df['EDAT_Q'].std()
print("Desviació estàndard:", desviacio_estandard_edat_q)
```


Desviació estàndard: 5.095017617214831

```
[ ]: # Desviació estàndard
import seaborn as sns
import matplotlib.pyplot as plt

mitjana_edat_quincenal = df['EDAT_Q'].mean()

sns.histplot(df['EDAT_Q'], bins=10, edgecolor='black', color='grey')
plt.axvline(mitjana_edat_quincenal, color='red', linestyle='dashed', linewidth=1, label=f'Mitjana: {mitjana_edat_quincenal:.2f}')

# Representacio grafic de la desviació estàndard
plt.axvline(mitjana_edat_quincenal + desviacio_estandard_edat_q, color='blue', linestyle='dashed', linewidth=1, label=f'Desviació Estàndard +1 : {mitjana_edat_quincenal + desviacio_estandard_edat_q:.3f}')
plt.axvline(mitjana_edat_quincenal - desviacio_estandard_edat_q, color='blue', linestyle='dashed', linewidth=1, label=f'Desviació Estàndard -1 : {mitjana_edat_quincenal - desviacio_estandard_edat_q:.3f}')
plt.legend()
plt.show()
```



Distribucions

```
[ ]: # Distribució de edat quincenal
percentil_25 = df['EDAT_Q'].quantile(0.25)
print(f'Percentil 25 : {int(percentil_25)}')
percentil_50 = df['EDAT_Q'].quantile(0.50)
print(f'Percentil 50 : {int(percentil_50)}')
percentil_75 = df['EDAT_Q'].quantile(0.75)
print(f'Percentil 75 : {int(percentil_75)}')
percentil_90 = df['EDAT_Q'].quantile(0.90)
print(f'Percentil 90 : {int(percentil_90)}')
percentil_95 = df['EDAT_Q'].quantile(0.95)
print(f'Percentil 95 : {int(percentil_95)}')
percentil_99 = df['EDAT_Q'].quantile(0.99)
print(f'Percentil 99 : {int(percentil_99)}')
```


```
Percentil 25 : 7
Percentil 50 : 11
Percentil 75 : 16
Percentil 90 : 18
Percentil 95 : 19
Percentil 99 : 20
```

```
[ ]: plt.hist(df['EDAT_Q'],color='gray', edgecolor='black')

plt.axvline(percentil_99, color='green', linestyle='--', label=f'Percentil 99:␣
↳{percentil_99:.2f}')
plt.axvline(percentil_25, color='red', linestyle='--', label=f'Percentil 25:␣
↳{percentil_25:.2f}')
plt.axvline(percentil_50, color='black', linestyle='--', label=f'Percentil 50:␣
↳{percentil_50:.2f}')

plt.legend()
plt.plot()
```

```
[ ]: []
```



2.1.4 Detecció de valors nuls, duplicats i anomalies

```
[ ]: df[df.duplicated(subset=['Valor'])]
```

```
[ ]:
Data Referencia  Codi Districte  Nom Districte  Codi Barri  \
1      2025-01-01              1  Ciutat Vella      1
3      2025-01-01              1  Ciutat Vella      1
5      2025-01-01              1  Ciutat Vella      1
6      2025-01-01              1  Ciutat Vella      1
7      2025-01-01              1  Ciutat Vella      1
...      ...              ...      ...      ...
11159  2025-01-01             10  Sant Martí      73
11160  2025-01-01             10  Sant Martí      73
11161  2025-01-01             10  Sant Martí      73
11162  2025-01-01             10  Sant Martí      73
11163  2025-01-01             10  Sant Martí      73

      Nom Barri  Valor  NIV_EDUCA_esta  EDAT_Q  SEXE
1      el Raval    ..              1      5      1
3      el Raval    ..              1      6      1
5      el Raval    ..              1      7      1
6      el Raval    8              1      7      2
```

7		el Raval	..		1	8	1
...		...	...	...	...	...	...
11159	la Verneda i la Pau	6		5	18	2	
11160	la Verneda i la Pau	..		5	19	2	
11161	la Verneda i la Pau	..		5	20	1	
11162	la Verneda i la Pau	25		6	3	1	
11163	la Verneda i la Pau	19		6	3	2	

[10332 rows x 9 columns]

```
[ ]: df[df.duplicated(subset=['EDAT_Q'], keep=False)]
```

```
[ ]:      Data_referencia  Codi_Districte Nom_Districte  Codi_Barri \
0      2025-01-01          1  Ciutat Vella          1
1      2025-01-01          1  Ciutat Vella          1
2      2025-01-01          1  Ciutat Vella          1
3      2025-01-01          1  Ciutat Vella          1
4      2025-01-01          1  Ciutat Vella          1
...      ...      ...      ...      ...
11159    2025-01-01         10  Sant Martí          73
11160    2025-01-01         10  Sant Martí          73
11161    2025-01-01         10  Sant Martí          73
11162    2025-01-01         10  Sant Martí          73
11163    2025-01-01         10  Sant Martí          73
```

	Nom_Barri	Valor	NIV_EDUCA_esta	EDAT_Q	SEXE
0	el Raval	..	1	4	2
1	el Raval	..	1	5	1
2	el Raval	8	1	5	2
3	el Raval	..	1	6	1
4	el Raval	5	1	6	2
...	...	...	...	...	...
11159	la Verneda i la Pau	6	5	18	2
11160	la Verneda i la Pau	..	5	19	2
11161	la Verneda i la Pau	..	5	20	1
11162	la Verneda i la Pau	25	6	3	1
11163	la Verneda i la Pau	19	6	3	2

[11164 rows x 9 columns]

```
[ ]: # Eliminació de duplicats a la columna EDAT_Q
files_duplicats = df.drop_duplicates(subset=['EDAT_Q'], keep='first',
inplace=False)
files_duplicats
```

```
[ ]:      Data_referencia  Codi_Districte Nom_Districte  Codi_Barri Nom_Barri Valor \
0      2025-01-01          1  Ciutat Vella          1  el Raval  ..
```


1	2025-01-01	1	Ciutat Vella	1	el Raval	..
3	2025-01-01	1	Ciutat Vella	1	el Raval	..
5	2025-01-01	1	Ciutat Vella	1	el Raval	..
7	2025-01-01	1	Ciutat Vella	1	el Raval	..
9	2025-01-01	1	Ciutat Vella	1	el Raval	..
11	2025-01-01	1	Ciutat Vella	1	el Raval	..
13	2025-01-01	1	Ciutat Vella	1	el Raval	..
15	2025-01-01	1	Ciutat Vella	1	el Raval	..
16	2025-01-01	1	Ciutat Vella	1	el Raval	..
18	2025-01-01	1	Ciutat Vella	1	el Raval	..
20	2025-01-01	1	Ciutat Vella	1	el Raval	..
22	2025-01-01	1	Ciutat Vella	1	el Raval	..
24	2025-01-01	1	Ciutat Vella	1	el Raval	89
26	2025-01-01	1	Ciutat Vella	1	el Raval	56
28	2025-01-01	1	Ciutat Vella	1	el Raval	22
30	2025-01-01	1	Ciutat Vella	1	el Raval	..
31	2025-01-01	1	Ciutat Vella	1	el Raval	372

	NIV_EDUCA_esta	EDAT_Q	SEXE
0	1	4	2
1	1	5	1
3	1	6	1
5	1	7	1
7	1	8	1
9	1	9	1
11	1	10	1
13	1	11	1
15	1	12	1
16	1	13	1
18	1	14	1
20	1	15	1
22	1	16	1
24	1	17	1
26	1	18	1
28	1	19	1
30	1	20	1
31	2	3	1

```
[ ]: # Verificació de duplicats després de netejar
df[df.duplicated(subset=['EDAT_Q'], keep=False)]
```

```
[ ]: Data_Referencia Codi_Districte Nom_Districte Codi_Barri \
0 2025-01-01 1 Ciutat Vella 1
1 2025-01-01 1 Ciutat Vella 1
2 2025-01-01 1 Ciutat Vella 1
3 2025-01-01 1 Ciutat Vella 1
4 2025-01-01 1 Ciutat Vella 1
```

```

...
11159      2025-01-01      10      Sant Martí      73
11160      2025-01-01      10      Sant Martí      73
11161      2025-01-01      10      Sant Martí      73
11162      2025-01-01      10      Sant Martí      73
11163      2025-01-01      10      Sant Martí      73

```

```

      Nom_Barri Valor NIV_EDUCA_esta EDAT_Q SEXE
0      el Raval  ..           1      4      2
1      el Raval  ..           1      5      1
2      el Raval   8           1      5      2
3      el Raval  ..           1      6      1
4      el Raval   5           1      6      2

```

```

...
11159  la Verneda i la Pau   6      5      18      2
11160  la Verneda i la Pau  ..      5      19      2
11161  la Verneda i la Pau  ..      5      20      1
11162  la Verneda i la Pau  25      6      3      1
11163  la Verneda i la Pau  19      6      3      2

```

[11164 rows x 9 columns]

```

[ ]: # Restaurar index després de la neteja
df.reset_index(drop=True)

```

```

[ ]:      DataReferencia Codi_Districte Nom_Districte Codi_Barri \
0      2025-01-01           1  Ciutat Vella           1
1      2025-01-01           1  Ciutat Vella           1
2      2025-01-01           1  Ciutat Vella           1
3      2025-01-01           1  Ciutat Vella           1
4      2025-01-01           1  Ciutat Vella           1
...
11159      2025-01-01           10    Sant Martí           73
11160      2025-01-01           10    Sant Martí           73
11161      2025-01-01           10    Sant Martí           73
11162      2025-01-01           10    Sant Martí           73
11163      2025-01-01           10    Sant Martí           73

```

```

      Nom_Barri Valor NIV_EDUCA_esta EDAT_Q SEXE
0      el Raval  ..           1      4      2
1      el Raval  ..           1      5      1
2      el Raval   8           1      5      2
3      el Raval  ..           1      6      1
4      el Raval   5           1      6      2
...
11159  la Verneda i la Pau   6      5      18      2
11160  la Verneda i la Pau  ..      5      19      2

```

11161	la Verneda i la Pau	..	5	20	1
11162	la Verneda i la Pau	25	6	3	1
11163	la Verneda i la Pau	19	6	3	2

[11164 rows x 9 columns]

2.1.5 Conclusió sobre: la qualitat de les dades, si són adequades per l'objectiu i si tenen alguna limitació.

Els dades d'aquest dataframe no és massa adequat perquè hi ha moltes dades repetits però es pot obtenir el resultat desitjat ja que amb les columnes específiques que volem fer servir es pot obtenir el rang d'edat, barri i sexe de la població a partir de 16 anys que més estudia.

2.2 Neteja de les dades: eliminació de valors nuls, eliminació de columnes no necessàries, filtrat per rangs o condicions, etc

Eliminació de valors nuls

```
[ ]: # Verificar s'hi ha valors nuls
df.isnull()
```

```
[ ]:      Data_Referencia  Codi_Districte  Nom_Districte  Codi_Barri  Nom_Barri  \
0                False                False                False                False
1                False                False                False                False
2                False                False                False                False
3                False                False                False                False
4                False                False                False                False
...                ...                ...                ...                ...
11159            False                False                False                False
11160            False                False                False                False
11161            False                False                False                False
11162            False                False                False                False
11163            False                False                False                False
```

	Valor	NIV_EDUCA_esta	EDAT_Q	SEXE
0	False	False	False	False
1	False	False	False	False
2	False	False	False	False
3	False	False	False	False
4	False	False	False	False
...	...	...	...	...
11159	False	False	False	False
11160	False	False	False	False
11161	False	False	False	False
11162	False	False	False	False
11163	False	False	False	False

[11164 rows x 9 columns]

```
[ ]: # Verificar la quantitat de valors nuls per columnes
# En aquest dataframe n'hi ha valors nuls
df.isnull().sum()
```

```
[ ]: Data Referencia      0
Codi_Districte          0
Nom_Districte           0
Codi_Barri              0
Nom_Barri               0
Valor                   0
NIV_EDUCA_esta          0
EDAT_Q                  0
SEXE                    0
dtype: int64
```

Eliminació de columnes no necessàries

```
[ ]: # Eliminació de aquestes columnes ja que no son essencials
df.drop(['Data Referencia', 'Codi_Districte', 'Codi_Barri'], axis=1,
        inplace=True)
```

Filtrat per rangs o condicions

```
[ ]: edat_max = df['EDAT_Q'].max()
edat_min = df['EDAT_Q'].min()
rang_edat = edat_max - edat_min
print(f"Rang d'edat: {rang_edat}")
```

Rang d'edat: 17

2.3 Manipulació del dataset: procés per obtenir les dades per a poder ser representades (com a mínim hi s'ha de realitzar un groupby o un merge)

```
[ ]: # Groupby
df2 = df.groupby('Nom_Barri')['EDAT_Q'].mean().reset_index()
df2
```

```
[ ]:
      Nom_Barri      EDAT_Q
0      Baró de Viver  10.492188
1      Can Baró      11.294521
2      Can Peguera   10.844961
3      Canyelles     11.055944
4      Ciutat Meridiana 10.862069
..      ...
68  la Vila Olímpica del Poblenou 11.134752
69      la Vila de Gràcia  11.481481
70      les Corts        11.443038
71      les Roquetes     11.013423
72      les Tres Torres   11.503356
```

[73 rows x 2 columns]

2.4 Representació de les dades i interpretació: Mínim 3 gràfics de tipus diferent on cada gràfic ha d'incloure la conclusió que voleu il·lustrar.

```
[ ]: import matplotlib.pyplot as plt

# Convertir de veritat a número
df['Valor'] = pd.to_numeric(df['Valor'], errors='coerce')

# Eliminar files que no han pogut convertir-se
df = df.dropna(subset=['Valor'])


# Agrupem per barri i sumem els estudiants
barri_dues = df.groupby('Nom_Barri')['Valor'].sum().
    ↪sort_values(ascending=False).head(10)

plt.figure(figsize=(12,6))
plt.bar(barri_dues.index, barri_dues.values)
plt.xlabel('Barri')
plt.ylabel('Nombre de persones')
plt.title('Top 10 barris amb més població que estudia')

# Rotar 45 grau el nom dels barris
plt.xticks(rotation=45, ha='right')

# Afegir una línia amb el valor de la mitjana
plt.axhline(barri_dues.mean(), color='red', linestyle='-', label='Mitjana')

# Afegim una llegenda
plt.legend()
plt.show()
```




3 Aquest grafic mostra el top 10 dels barris on mes la població estudia.

4 S'ha classificat els barris amb més activitat educativa segons els dades.

```
[ ]: # Agrupem i sumem els estudiants
edat_rang = df.groupby('EDAT_Q')['Valor'].sum().sort_index()

plt.figure(figsize=(10,6))
edat_rang.plot(kind='line', marker='o')
plt.title('Nombre d\'estudiants per rang d\'edat')
plt.xlabel('Rang d\'edat')
plt.ylabel('Nombre de persones')
plt.grid(True)
plt.show()
```




- 5 Aquest gràfic mostra quines rangs d'edat te una quantitat més alta d'estudiants.
- 6 Els rangs més elevats indiquen els grups que actualment tenen més participació educativa

```
[ ]: # Agrupem per nivel educatiu i sexe i sumen els estudiants
nivell_sexe = df.groupby(['NIV_EDUCA_esta', 'SEXE'])['Valor'].sum().unstack()

nivell_sexe.plot(kind='bar', figsize=(12,6))

plt.title("Distribució del nivell d'estudis per sexe")
plt.xlabel("Nivell d'estudis")
plt.ylabel("Nombre de persones")
plt.xticks(rotation=45)
plt.legend(title='Sexe')
plt.tight_layout()
plt.show()
```



- 7 Aquest gràfic mostra la distribució entre homes i dones.
- 8 El sexe que més estudia té una mediana superior, el que significa que generalment té un nivell d'estudis més elevat.