

N1_Lectura_i_inspeccio_de_fitxers_en_Python

November 26, 2025

1 Lectura de fitxers en Python

Primer de tot hauràs de pujar el fitxer notes.txt al sistema de fitxers de colab. Perquè tots els alumnes tingueu el mateix codi es proposa pujar el fitxer (“Upload to session storage”) dins del directori sample_data així podrem accedir als fitxers amb la següent ruta /content/sample_data/notes.txt

```
[ ]: file_path = "/content/sample_data/notes.txt"
```

1.0.1 Lectura de fitxers sense llibreries

A continuació es mostren un parell d'exemples de com Python llegiria un fitxer sense cap llibreria externa:

```
[ ]: fitxer = open(file_path, "r")

fitxer.readline()
linies=[]

for linia in fitxer:
    linies.append(linia.strip())

fitxer.close()

print(linies)
```

```
['Anna,8.5,7.0,9.0,8.0,7.5,9.0,8.5', 'Marc,6.5,8.0,7.0,7.5,8.0,7.0,7.5',
'Jordi,7.0,6.5,6.0,8.0,7.5,8.5,7.0', 'Laia,9.0,8.5,9.5,8.0,9.0,9.0,9.5',
'Carla,7.5,7.0,8.0,7.0,7.0,7.5,7.5', 'Pau,8.0,8.0,7.5,7.5,8.5,8.0,8.0',
'Núria,9.5,8.5,8.0,9.0,9.5,8.0,9.0', 'Alex,6.0,6.5,7.0,6.5,6.0,6.0,6.5',
'Marta,8.0,9.0,8.5,8.5,8.0,8.5,9.0', 'Joel,7.0,7.0,6.5,7.5,7.5,7.0,7.0']
```

```
[ ]: with open(file_path, "r", encoding="utf-8") as f:
    f.readline()
    lines = [linia.strip() for linia in f]
print(lines)
```

```
['Anna,8.5,7.0,9.0,8.0,7.5,9.0,8.5', 'Marc,6.5,8.0,7.0,7.5,8.0,7.0,7.5',
'Jordi,7.0,6.5,6.0,8.0,7.5,8.5,7.0', 'Laia,9.0,8.5,9.5,8.0,9.0,9.0,9.5',
```

```
'Carla,7.5,7.0,8.0,7.0,7.0,7.5,7.5', 'Pau,8.0,8.0,7.5,7.5,8.5,8.0,8.0',
'Núria,9.5,8.5,8.0,9.0,9.5,8.0,9.0', 'Alex,6.0,6.5,7.0,6.5,6.0,6.0,6.5',
'Marta,8.0,9.0,8.5,8.5,8.0,8.5,9.0', 'Joel,7.0,7.0,6.5,7.5,7.5,7.0,7.0']
```

Observa com amb l'ús de l'estructura with ... as no és necessari tancar el fitxer (la mateixa estructura se n'encarrega).

1.0.2 Lectura de fitxers amb llibreria Pandas

A l'entorn colab no serà necessari instal·lar cap llibreria perquè per defecte ja té instal·lades les principals llibreries utilitzades en *Data Science*. En cas que vulguis reproduir els exemples en local hauries d'instal·lar la llibreria pandas.

pip install pandas

I prèviament hauries d'haver instal·lat l'instal·lador de paquets de python pip

sudo apt install python3-pip

Existeixen instal·lars més moderns, sobretot si utilitzeu entorns virtuals com ara uv. Si en vols saber més pregunta a la teva professora.

```
[ ]: import pandas as pd

df = pd.read_csv(file_path, delimiter=',')
```

Una primera exploració de les dades, sobretot quan el volum de dades és molt gran

```
[ ]: # Ens mostra els primers 4 elements
df.head(4)
```

```
[ ]:  Alumn     Programació  Bases_de_dades  Llenguatges_de_marques  \
0   Anna             8.5             7.0             9.0
1   Marc             6.5             8.0             7.0
2   Jordi            7.0             6.5             6.0
3   Laia             9.0             8.5             9.5

      Sistemes_informàtics  Desenvolupament_d'interfícies  Machine Learning  \
0                8.0                7.5                9.0
1                7.5                8.0                7.0
2                8.0                7.5                8.5
3                8.0                9.0                9.0

      Projecte
0           8.5
1           7.5
2           7.0
3           9.5
```

```
[ ]: # Ens mostra els últims 4 elements
df.tail(4)
```

```
[ ]:  Alumne  Programació  Bases_de_dades  Llenguatges_de_marques  \
6  Núria          9.5          8.5          8.0
7  Alex           6.0          6.5          7.0
8  Marta          8.0          9.0          8.5
9  Joel           7.0          7.0          6.5

      Sistemes_informàtics  Desenvolupament_d'interfícies  Machine Learning  \
6              9.0              9.5              8.0
7              6.5              6.0              6.0
8              8.5              8.0              8.5
9              7.5              7.5              7.0

      Projecte
6      9.0
7      6.5
8      9.0
9      7.0
```

Explocació de les dades amb pandas per veure quines són les seves característiques.

```
[ ]: # Les dimensions de la taula de dades
df.shape
```

```
[ ]: (10, 8)
```

```
[ ]: # Dades estadístiques sobre les dades
df.describe()
```

```
[ ]:  count  Programació  Bases_de_dades  Llenguatges_de_marques  \
count    10.000000      10.000000      10.000000
mean       7.700000       7.600000       7.700000
std        1.110555       0.906765       1.110555
min         6.000000       6.500000       6.000000
25%         7.000000       7.000000       7.000000
50%         7.750000       7.500000       7.750000
75%         8.375000       8.375000       8.375000
max         9.500000       9.000000       9.500000

      Sistemes_informàtics  Desenvolupament_d'interfícies  Machine Learning  \
count           10.00000      10.000000      10.000000
mean            7.75000      7.850000      7.850000
std             0.71686      1.001388      0.973253
min             6.50000      6.000000      6.000000
25%             7.50000      7.500000      7.125000
50%             7.75000      7.750000      8.000000
75%             8.00000      8.375000      8.500000
max             9.00000      9.500000      9.000000
```

	Projecte
count	10.000000
mean	7.950000
std	1.012423
min	6.500000
25%	7.125000
50%	7.750000
75%	8.875000
max	9.500000

```
[ ]: # Tipus de dades contingudes i presència de valors nulls o invàlids
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10 entries, 0 to 9
Data columns (total 8 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Alumne                                10 non-null     object
1   Programació                           10 non-null     float64
2   Bases_de_dades                        10 non-null     float64
3   Llenguatges_de_marques                10 non-null     float64
4   Sistemes_informàtics                  10 non-null     float64
5   Desenvolupament_d'interfícies         10 non-null     float64
6   Machine Learning                      10 non-null     float64
7   Projecte                              10 non-null     float64
dtypes: float64(7), object(1)
memory usage: 772.0+ bytes
```

També podem utilitzar la possibilitat de ofereix l'entorn Jupyter Notebook per “incrustar” comandes de Terminal de Linux precedides per un !

```
[ ]: !wget https://raw.githubusercontent.com/I-Onna/dades/refs/heads/main/notes.txt
```

```
--2025-10-30 20:43:21--
https://raw.githubusercontent.com/I-Onna/dades/refs/heads/main/notes.txt
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.109.133, 185.199.108.133, 185.199.111.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.109.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 470 [text/plain]
Saving to: 'notes.txt'

notes.txt          100%[=====]          470  --.-KB/s    in 0s

2025-10-30 20:43:21 (17.3 MB/s) - 'notes.txt' saved [470/470]
```

Podem inclús fer ús de les comandes típiques de gestió de fitxers unix ls, cd, mkdir, Aquest cop els utilitzarem per saber la ruta on s'ha guardat el fitxer que hem descarregat.

```
[ ]: !ls
```

```
notes.txt  sample_data
```

```
[ ]: !pwd
```

```
/content
```

Amb aquesta informació especifiquem la nova ruta del fitxer notes.txt

```
[ ]: file_path_download = "/content/sample_data/notes.txt"
```

```
[ ]: df_download = pd.read_csv(file_path_download, delimiter=',')
```

```
[ ]: # EXERCICI 1: Fes l'exploració bàsica de les dades del fitxer notes.txt (que  
    ↪ t'hauria de donar el mateix resultat que l'anterior)  
import pandas as pd  
  
df = pd.read_csv(file_path, delimiter=',')
```

```
[ ]: df.head(4)
```

```
[ ]:  Alumne  Programació  Bases_de_dades  Llenguatges_de_marques  \  
0    Anna           8.5           7.0           9.0  
1    Marc           6.5           8.0           7.0  
2    Jordi          7.0           6.5           6.0  
3    Laia           9.0           8.5           9.5  
  
      Sistemes_informàtics  Desenvolupament_d'interfícies  Machine Learning  \  
0                8.0                7.5                9.0  
1                7.5                8.0                7.0  
2                8.0                7.5                8.5  
3                8.0                9.0                9.0  
  
      Projecte  
0            8.5  
1            7.5  
2            7.0  
3            9.5
```

```
[ ]: df.tail(4)
```

```
[ ]:  Alumne  Programació  Bases_de_dades  Llenguatges_de_marques  \  
6  Núria           9.5           8.5           8.0  
7   Alex           6.0           6.5           7.0  
8  Marta           8.0           9.0           8.5
```

9	Joel	7.0	7.0	6.5
---	------	-----	-----	-----

	Sistemes_informàtics	Desenvolupament_d'interfícies	Machine Learning	\
6	9.0	9.5	8.0	
7	6.5	6.0	6.0	
8	8.5	8.0	8.5	
9	7.5	7.5	7.0	

	Projecte
6	9.0
7	6.5
8	9.0
9	7.0

```
[ ]: df.shape
```

```
[ ]: (10, 8)
```

```
[ ]: df.describe()
```

```
[ ]:
```

	Programació	Bases_de_dades	Llenguatges_de_marques	\
count	10.000000	10.000000	10.000000	
mean	7.700000	7.600000	7.700000	
std	1.110555	0.906765	1.110555	
min	6.000000	6.500000	6.000000	
25%	7.000000	7.000000	7.000000	
50%	7.750000	7.500000	7.750000	
75%	8.375000	8.375000	8.375000	
max	9.500000	9.000000	9.500000	

	Sistemes_informàtics	Desenvolupament_d'interfícies	Machine Learning	\
count	10.00000	10.000000	10.000000	
mean	7.75000	7.850000	7.850000	
std	0.71686	1.001388	0.973253	
min	6.50000	6.000000	6.000000	
25%	7.50000	7.500000	7.125000	
50%	7.75000	7.750000	8.000000	
75%	8.00000	8.375000	8.500000	
max	9.00000	9.500000	9.000000	

	Projecte
count	10.000000
mean	7.950000
std	1.012423
min	6.500000
25%	7.125000
50%	7.750000

```
75%      8.875000
max      9.500000
```

```
[ ]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10 entries, 0 to 9
Data columns (total 8 columns):
 #   Column                                Non-Null Count  Dtype
---  -
 0   Alumne                               10 non-null     object
 1   Programació                         10 non-null     float64
 2   Bases_de_dades                      10 non-null     float64
 3   Llenguatges_de_marques              10 non-null     float64
 4   Sistemes_informàtics                10 non-null     float64
 5   Desenvolupament_d'interfícies       10 non-null     float64
 6   Machine Learning                   10 non-null     float64
 7   Projecte                            10 non-null     float64
dtypes: float64(7), object(1)
memory usage: 772.0+ bytes
```

```
[ ]: # EXERCICI 2: Comenta en una cel·la a continuació d'aquest enunciat, quin dels
      ↪ dos mètodes t'ha semblar més fàcil per accedir a les dades.
      # Explora i utilitza les diferents possibilitats que t'ofereix markdown.
```

```
[ ]:
```