

N4_bis_EXTRA_Recodificacio_(relacionat_amb_el_Projecte)

November 26, 2025

1 Recodificació

Aquí tens un exemple senzill que involucra dos datasets ficticis d'Open Data de la Generalitat o Barcelona, per a la manipulació amb pandas per convertir un paràmetre numèric en categòric a partir d'una taula de traducció:

```
[ ]: import pandas as pd

# Dataset principal: ofertes d'ocupació a Barcelona
df_ofertes = pd.DataFrame({
    'id_oferta': [1, 2, 3, 4],
    'codi_ocupacio': [101, 102, 103, 104],
    'sou_base': [1200, 1500, 1300, 1600]
})

df_ofertes.head()
```

```
[ ]:   id_oferta  codi_ocupacio  sou_base
0          1           101      1200
1          2           102      1500
2          3           103      1300
3          4           104      1600
```

```
[ ]: # Dataset de traducció: correspondència codi ocupació amb la categoria de
    ↪ l'oferta
df_traduccion = pd.DataFrame({
    'codi_ocupacio': [101, 102, 103, 104],
    'categoria_oferta': ['Administració', 'Tecnologia', 'Sanitat', 'Educació']
})

df_traduccion.head()
```

```
[ ]:   codi_ocupacio  categoria_oferta
0          101      Administració
1          102      Tecnologia
2          103          Sanitat
3          104          Educació
```

Fer un *merge* és una de les opcions més fàcils i directes i ens permet mantenir la columna dels codis.

```
[ ]: df_ofertes_traduccio = df_ofertes.merge(df_traduccio, on='codi_ocupacio')
df_ofertes_traduccio.head()
```

```
[ ]:   id_oferta  codi_ocupacio  sou_base categoria_oferta
0         1         101        1200      Administració
1         2         102        1500      Tecnologia
2         3         103        1300        Sanitat
3         4         104        1600      Educació
```


Ja podem fer alguns tipus de manipulacions perquè les gràfiques siguin més comprensibles:

```
[ ]: df = df_ofertes_traduccio.groupby('categoria_oferta')['sou_base'].mean().
    ↪reset_index()
df.head()
```

```
[ ]:   categoria_oferta  sou_base
0   Administració    1200.0
1   Educació        1600.0
2   Sanitat         1300.0
3   Tecnologia      1500.0
```

```
[ ]: import seaborn as sns
import matplotlib.pyplot as plt

sns.barplot(x='categoria_oferta', y='sou_base', data=df_ofertes_traduccio, hue=
    ↪ 'categoria_oferta', palette='pastel')
plt.title("Sou base per categoria")
plt.xlabel('Categoria')
plt.ylabel("Sou base")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



```
[ ]: df = df_ofertes_traduccio.groupby('codi_ocupacio')['sou_base'].mean().
      ↪reset_index()
df.head()
```

```
[ ]:   codi_ocupacio  sou_base
0      101      1200.0
1      102      1500.0
2      103      1300.0
3      104      1600.0
```

Molt més clara que el gràfic següent, que tot i que seaborn afegeix una llegenda no aporta massa per entendre el contingut del gràfic.

```
[ ]: import seaborn as sns
import matplotlib.pyplot as plt

sns.barplot(x='codi_ocupacio', y='sou_base', data=df, hue = 'codi_ocupacio',
            ↪palette='pastel')
plt.title("Sou base per categoria")
plt.xlabel('Categoria')
plt.ylabel("Sou base")
```

```
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

